EXTRACTION D'INFORMATION – BILAN DU TP

Du texte aux entités

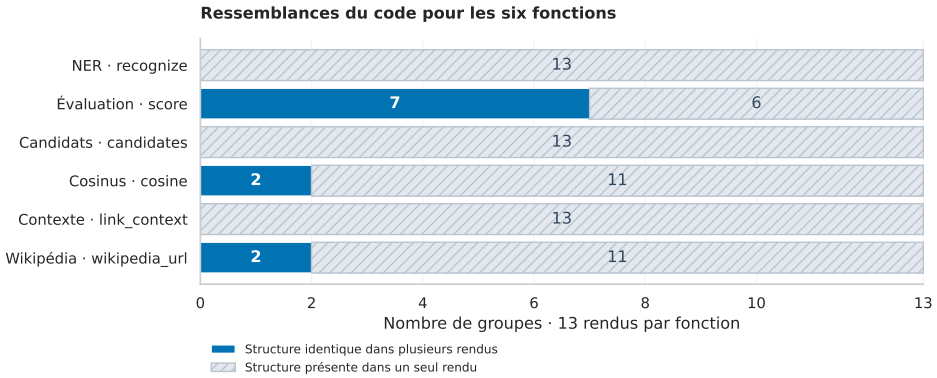
Vous avez travaillé sur deux tâches complémentaires : repérer les entités nommées dans un texte (NER) [1], puis retrouver l'entité qu'ils désignent dans une base de connaissances (NEL). Le parcours allait de la reconnaissance par dictionnaire à la liaison contextuelle, avant la comparaison avec une IA générative.

Les exercises

Les cinq premières fonctions ont été (bien) effectués dans les 13 rendus (juste la fonction de lien Wikipédia l'a été dans 12 rendus).

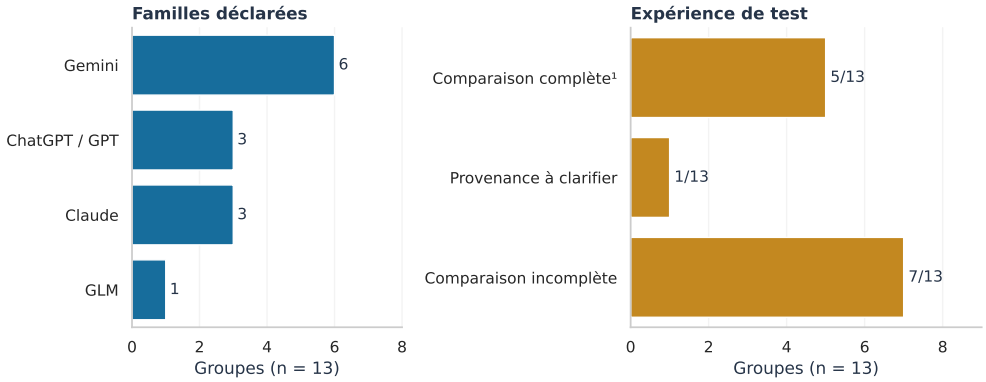
Mais les fonctions de code qui devaient être complétées ont-elles été réalisées par l'IA ?

Pour le plaisir, essayons de voir si une IA a été utilisée :). Il semble que sept groupes partagent une structure identique pour la méthode `score` ; deux pour `cosine` et deux pour `wikipedia_url`. Pour les trois fonctions restantes, les structures comparées sont totalement différentes. Cela ne signifie pas nécessairement qu'une IA a été utilisée ; contentons-nous de supposer ce que cet article a dit [2].



La partie bleue compte les groupes dont la fonction possède la même structure que celle d'au moins un autre rendu ; la partie hachurée compte les structures uniques dans cet ensemble.

Les modèles que vous avez choisis



Gemini remporte le concours de popularité avec 6 groupes sur 13, devant ChatGPT/GPT et Claude (3 chacun), puis GLM (1). Mais le plus choisi n'est pas forcément le meilleur : dans ce TP, ces modèles devaient reconnaître les entités, choisir la bonne identité et produire du JSON valide... Certains modèles

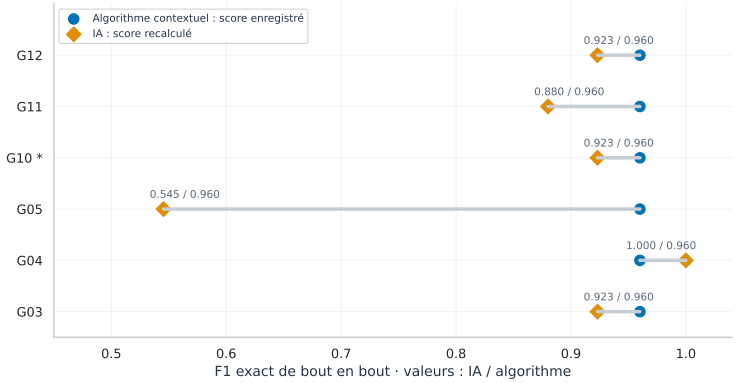
1. Les textes et les entités du TP sont fictifs. Le test comprend 6 documents et 13 mentions.
2. Suh et al., *An Empirical Study on Automatically Detecting AI-Generated Source Code : How Far Are We ?*, ICSE 2025. `https://arxiv.org/abs/2411.04299`

avaient tendance à être assez bavards... c'est moins le cas récemment, peut-être seulement pour ceux à poids ouverts.

Aussi, vos choix privilégient les modèles propriétaires à poids fermés : Gemini, les GPT utilisés dans ChatGPT et Claude. Il est aussi intéressant de voir GLM représenté, avec une famille proposant des modèles à poids ouverts : une occasion de découvrir d'autres options que les plateformes les plus connues !

Les résultats

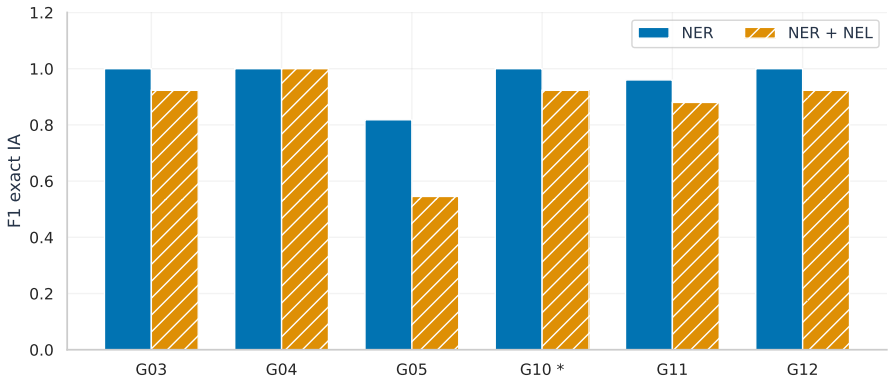
Sur les cinq comparaisons retenues, votre algorithme contextuel obtient un meilleur F1 dans quatre cas ; l'IA générative obtient le meilleur score dans un cas. → Il semble qu'un modèle génératif n'est pas automatiquement le plus performant pour une tâche précise. Le résultat dépend des ressources disponibles, des consignes et du traitement des sorties. Ici, les expériences diffèrent et le test est petit : elles illustrent des comportements, sans établir un classement général des modèles.



F1 exact : le segment, le type et l'identifiant doivent tous correspondre à la référence. Scores IA recalculés avec le parseur du TP ; scores algorithmiques issus des sorties enregistrées. * G10 est affiché hors synthèse comparative. L'axe commence à 0,45.

De la mention à l'identité

Les performances sont élevées, mais cela est incompréhensible avec un corpus aussi restreint. En réalité, les performances d'un système NEL sont d'environ 50%. Quoi qu'il en soit, il est intéressant de constater qu'une IA peut se tromper même avec un ensemble de données aussi petit.



Pour analyser une erreur, examinez successivement les frontières de la mention, son type, la présence du bon candidat, le choix de l'identifiant et la validité du format de sortie.

Ce TP visait à démontrer qu'une méthode simple, adaptée à la tâche et enrichie par le contexte, peut rivaliser avec l'IA générative. Toutefois, l'ensemble de vos travaux et observations reste propre au corpus limité de cet exercice ; il vous appartient désormais de vérifier la validité de ces résultats face à des textes plus complexes !